Настройка

```
import gym
import numpy as np
import tensorflow as tf
from tensorflow import keras
from tensorflow.keras import layers

# Параметры конфигурации для всей установки
seed = 42
gamma = 0.99  # Discount factor для прошлых вознаграждений
max_steps_per_episode = 10000
env = gym.make("CartPole-v0")  # Создание среды
env.seed(seed)
eps = np.finfo(np.float32).eps.item()  # Наименьшее число, такое что 1.0 + eps != 1.0
```

```
/usr/local/lib/python3.10/dist-packages/gym/envs/registration.py:593: UserWarning: WARN: The environment CartPole-v0 is out of date
  logger.warn(
/usr/local/lib/python3.10/dist-packages/gym/core.py:256: DeprecationWarning: WARN: Function `env.seed(seed)` is marked as deprecate
  deprecation(
```

+ Код + Текст

Построение модели нейронной сети

```
num_inputs = 4
num_actions = 2
num_hidden = 128

inputs = layers.Input(shape=(num_inputs,))
common = layers.Dense(num_hidden, activation="relu")(inputs)
action = layers.Dense(num_actions, activation="softmax")(common)
critic = layers.Dense(1)(common)

model = keras.Model(inputs=inputs, outputs=[action, critic])
```

Обучение

```
optimizer = keras.optimizers.Adam(learning_rate=0.01)
huber_loss = keras.losses.Huber()
action_probs_history = []
critic_value_history = []
rewards_history = []
running_reward = 0
episode_count = 0

while True:  # Выполнять до решения
    state = env.reset()
    episode_reward = 0
    with tf.GradientTape() as tape:
        for timestep in range(1, max_steps_per_episode):
            # env.render(); Adding this line would show the attempts
            # of the agent in a pop up window.

            state = tf.convert_to_tensor(state)
            state = tf.expand_dims(state, 0)

            # Предсказываем вероятности действий и предполагаемое
            # будущее вознаграждение из состояния среды
            action_probs, critic_value = model(state)
            critic_value_history.append(critic_value[0, 0])

            # Выборка действий из распределения вероятностей действий
            action = np.random.choice(num_actions, p=np.squeeze(action_probs))
            action_probs_history.append(tf.math.log(action_probs[0, action]))

            # Примените выбранное действие в нашем окружении
            state, reward, done, _ = env.step(action)
            rewards_history.append(reward)
            episode_reward += reward

            if done:
                break
```

```
        # Обновление вознаграждения за выполнение для проверки условия решения
        running_reward = 0.05 * episode_reward + (1 - 0.05) * running_reward

        # Вычислите ожидаемое значение из вознаграждений
        # - На каждом временном шаге каково общее вознаграждение,
        #полученное после этого временного шага.
        # - Вознаграждения в прошлом дисконтируются путем умножения их на гамму
        # - Это метки для нашего критика
        returns = []
        discounted_sum = 0
        for r in rewards_history[::-1]:
            discounted_sum = r + gamma * discounted_sum
            returns.insert(0, discounted_sum)

        # Нормализация
        returns = np.array(returns)
        returns = (returns - np.mean(returns)) / (np.std(returns) + eps)
        returns = returns.tolist()

        # Вычисление значений потерь для обновления нашей сети
        history = zip(action_probs_history, critic_value_history, returns)
        actor_losses = []
        critic_losses = []
        for log_prob, value, ret in history:
            # В этот момент истории критик оценил, что в будущем мы получим
            # общую награду = `value`. Мы предприняли действие с вероятностью
            # log_prob и в итоге получили общую награду = `ret`. Актор должен
            # быть обновлен таким образом, чтобы он предсказывал действие,
            # которое приведет к высокой награде (по сравнению с оценкой
            # критика) с высокой вероятностью.
            diff = ret - value
            actor_losses.append(-log_prob * diff)  # actor loss

            # Критик должен быть обновлен так, чтобы он предсказывал лучшую
            # оценку будущих вознаграждений.
            critic_losses.append(
                huber_loss(tf.expand_dims(value, 0), tf.expand_dims(ret, 0))
            )

        # Обратное распространение
        loss_value = sum(actor_losses) + sum(critic_losses)
        grads = tape.gradient(loss_value, model.trainable_variables)
        optimizer.apply_gradients(zip(grads, model.trainable_variables))

        # Очиститка истории потерь и вознаграждений
        action_probs_history.clear()
        critic_value_history.clear()
        rewards_history.clear()

    # Log details
    episode_count += 1
    if episode_count % 10 == 0:
        template = "вознаграждение: {:.2f} за эпизод {}"
        print(template.format(running_reward, episode_count))

    if running_reward > 150:  # Условие считать задачу решенной
        print("Решено в эпизоде {}!".format(episode_count))
        break
```

```
 вознаграждение: 11.09 за эпизод 10
 вознаграждение: 21.22 за эпизод 20
 вознаграждение: 29.93 за эпизод 30
 вознаграждение: 43.69 за эпизод 40
 вознаграждение: 51.97 за эпизод 50
 вознаграждение: 93.71 за эпизод 60
 вознаграждение: 98.59 за эпизод 70
 вознаграждение: 85.83 за эпизод 80
 вознаграждение: 106.82 за эпизод 90
 вознаграждение: 143.25 за эпизод 100
 вознаграждение: 133.76 за эпизод 110
 вознаграждение: 116.59 за эпизод 120
 вознаграждение: 100.67 за эпизод 130
 вознаграждение: 125.94 за эпизод 140
 Решено в эпизоде 149!
```

Визуализация

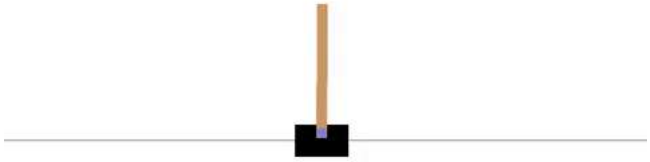

Ранняя стадия обучения:

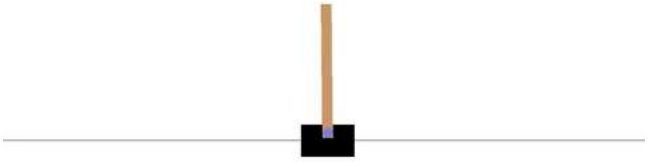

Поздняя стадия обучения:

0 сек. выполнено в 13:41